



Institución  
**Universitaria**  
Reacreditada en Alta Calidad

# Optimización

## Optimización sin restricciones

**Docente: Cristian Guarnizo Lemus**

Somos Innovación Tecnológica con *Sentido Humano*

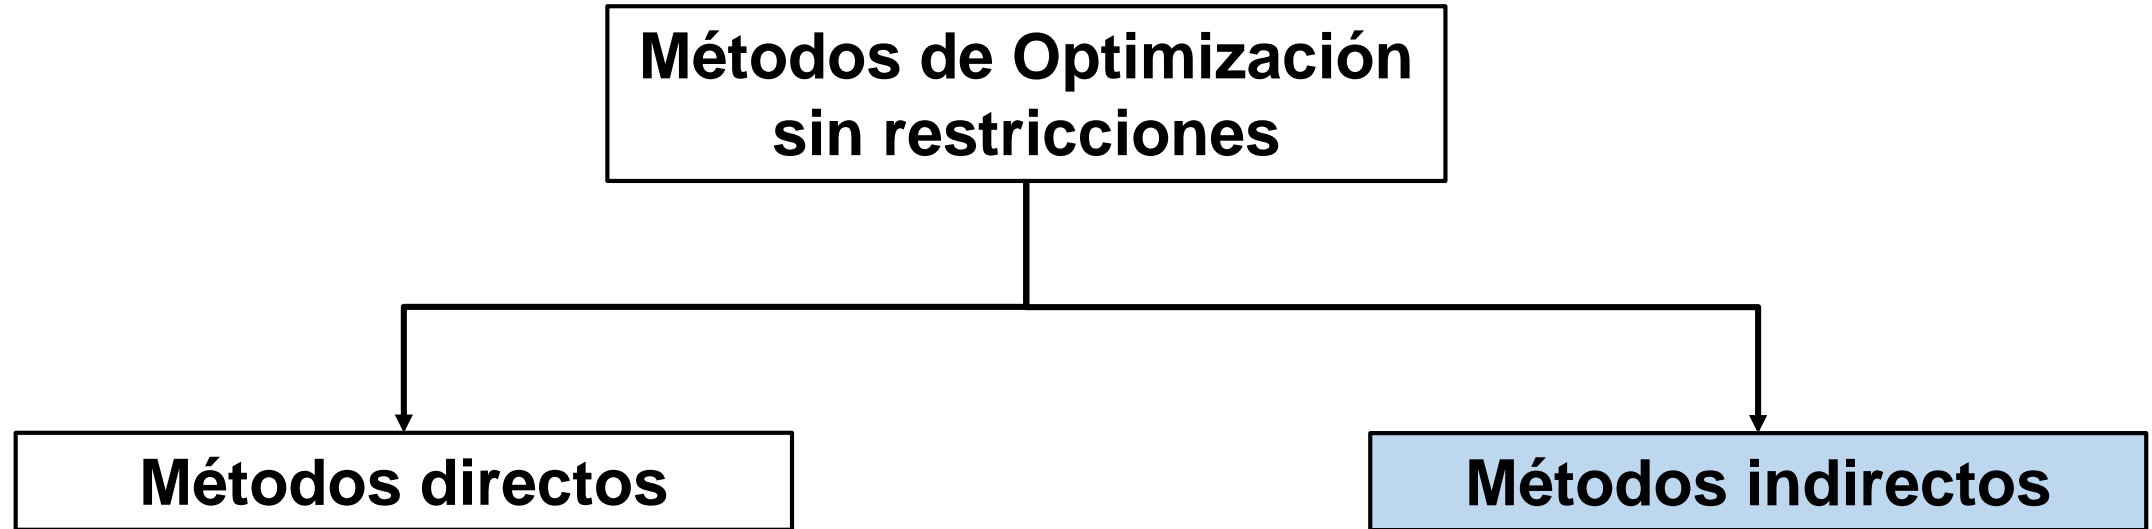


Alcaldía de Medellín

# Contenido

1. Métodos de solución para Optimización sin restricciones.
2. Búsqueda en una línea. (Condiciones de Armijo y Wolfe seleccionar paso)
3. Determinación de la dirección (Steepest, Conjugate, Newton's)

# Métodos de solución para Optimización sin restricciones



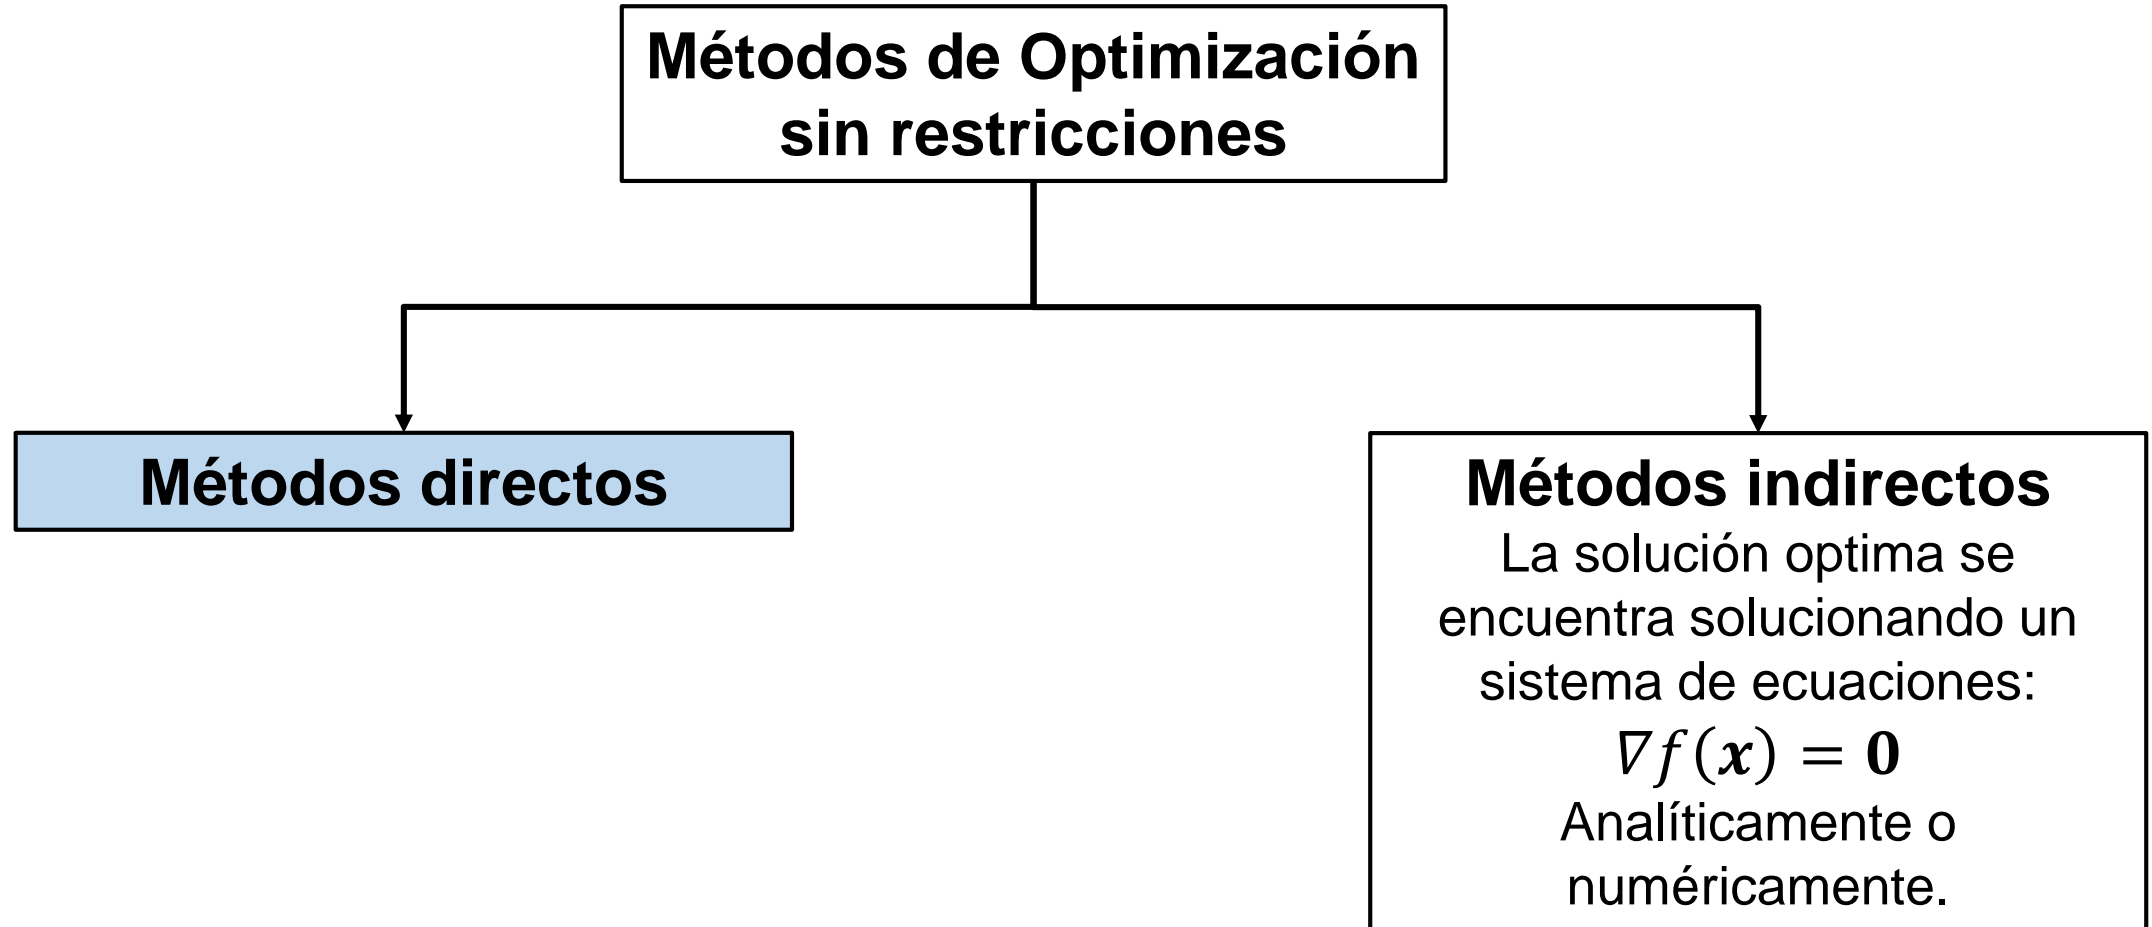
# Métodos indirectos - Concepto

- Condiciones necesarias de primer orden

$$\nabla f(\mathbf{x}) = \mathbf{0} \Leftrightarrow \begin{cases} \left. \frac{\partial f}{\partial x_1} \right|_{\mathbf{x}} = 0 = g_1(\mathbf{x}) \\ \left. \frac{\partial f}{\partial x_2} \right|_{\mathbf{x}} = 0 = g_2(\mathbf{x}) \\ \vdots \\ \left. \frac{\partial f}{\partial x_n} \right|_{\mathbf{x}} = 0 = g_n(\mathbf{x}) \end{cases} \Leftrightarrow \begin{matrix} \text{Sistema de ecuaciones no} \\ \text{lineales} \\ \\ \mathbf{g}(\mathbf{x}) = \mathbf{0} \end{matrix}$$

- La solución óptima es encontrada **solucionando el sistema de ecuaciones** analíticamente o numéricamente. (p.e. con el Método de Newton).
- Diferenciar y solucionar un sistema de ecuaciones es **difícil para sistemas complejos**.


# Métodos de solución para Optimización sin restricciones



# Métodos directos - Concepto

Idea: Construir una secuencia convergente de  $\{\mathbf{x}^{(k)}\}_{k=1}^{\infty}$ , que satisfaga las siguientes condiciones:

$$\exists \bar{k} \geq 0: f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)}) \quad \forall k > \bar{k} \quad \text{y} \quad \lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^* \in R^n$$





# Métodos directos - Concepto

Idea: Construir una secuencia convergente de  $\{x^{(k)}\}_{k=1}^{\infty}$ , que satisfaga las siguientes condiciones:

$$\exists \bar{k} \geq 0: f(x^{(k+1)}) < f(x^{(k)}) \quad \forall k > \bar{k} \quad \text{y} \quad \lim_{k \rightarrow \infty} x^{(k)} = x^* \in R^n$$

## Convergencia:

- **Lineal**: Sí existe una constante  $C \in (0,1)$ , tal que para un  $k$  suficientemente largo:

$$\|x^{(k+1)} - x^{(k)}\| \leq C \|x^{(k)} - x^*\|$$

- **Orden P**: Sí existe una constante  $M > 0$ , tal que

$$\|x^{(k+1)} - x^{(k)}\| \leq M \|x^{(k)} - x^*\|^p$$

- **Superlineal**: Sí existe una secuencia  $c_k$  convergente a cero.

$$\|x^{(k+1)} - x^{(k)}\| \leq c_k \|x^{(k)} - x^*\|$$

# Métodos de solución para Optimización sin restricciones

## Métodos de Optimización sin restricciones



```
graph TD; A[Métodos de Optimización sin restricciones] --> B[Métodos directos]; A --> C[Métodos indirectos];
```

### Métodos directos

La solución optima se encuentra mejorando la función objetivo por medio de **iteraciones descendentes**.

### Métodos indirectos

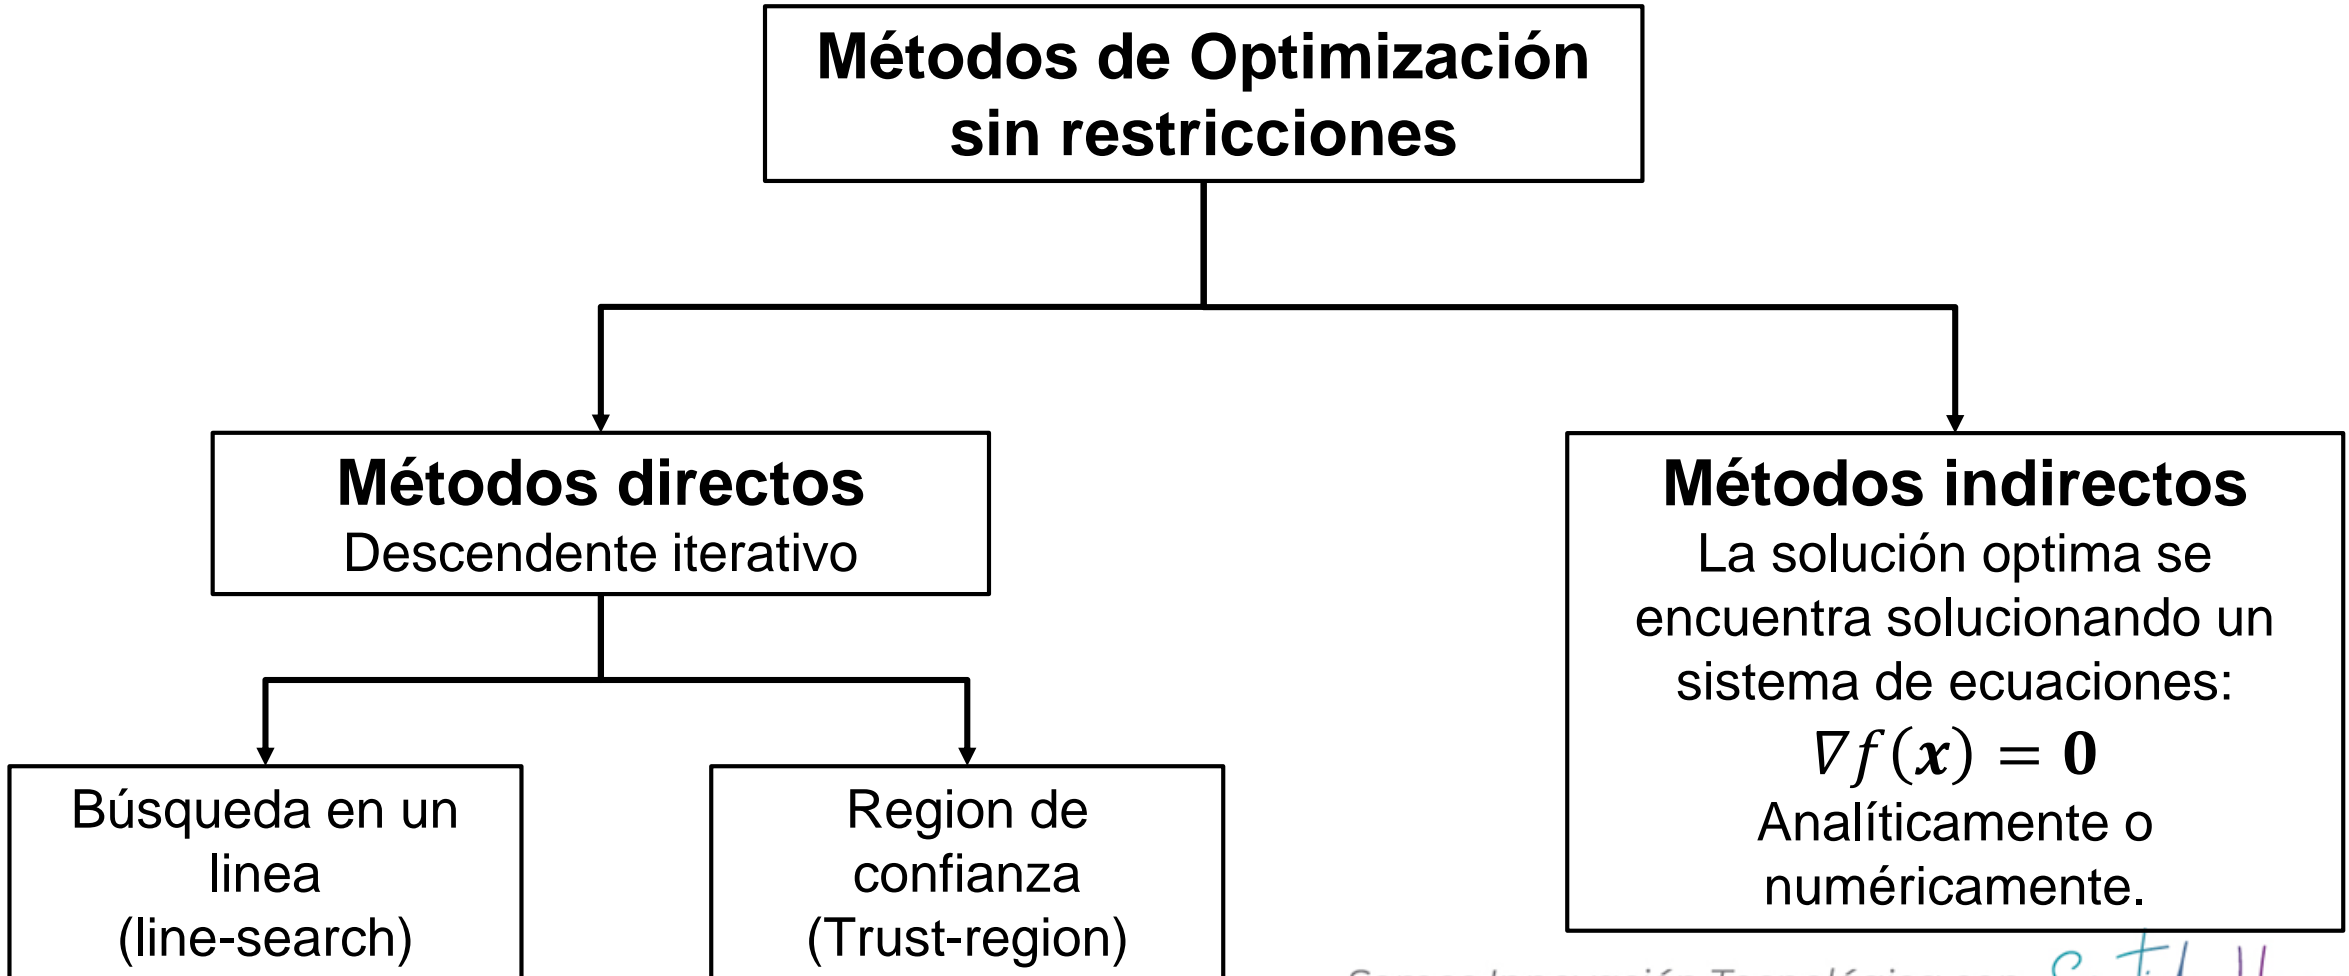
La solución optima se encuentra solucionando un sistema de ecuaciones:

$$\nabla f(\mathbf{x}) = \mathbf{0}$$

Analíticamente o numéricamente.



# Métodos de solución para Optimización sin restricciones

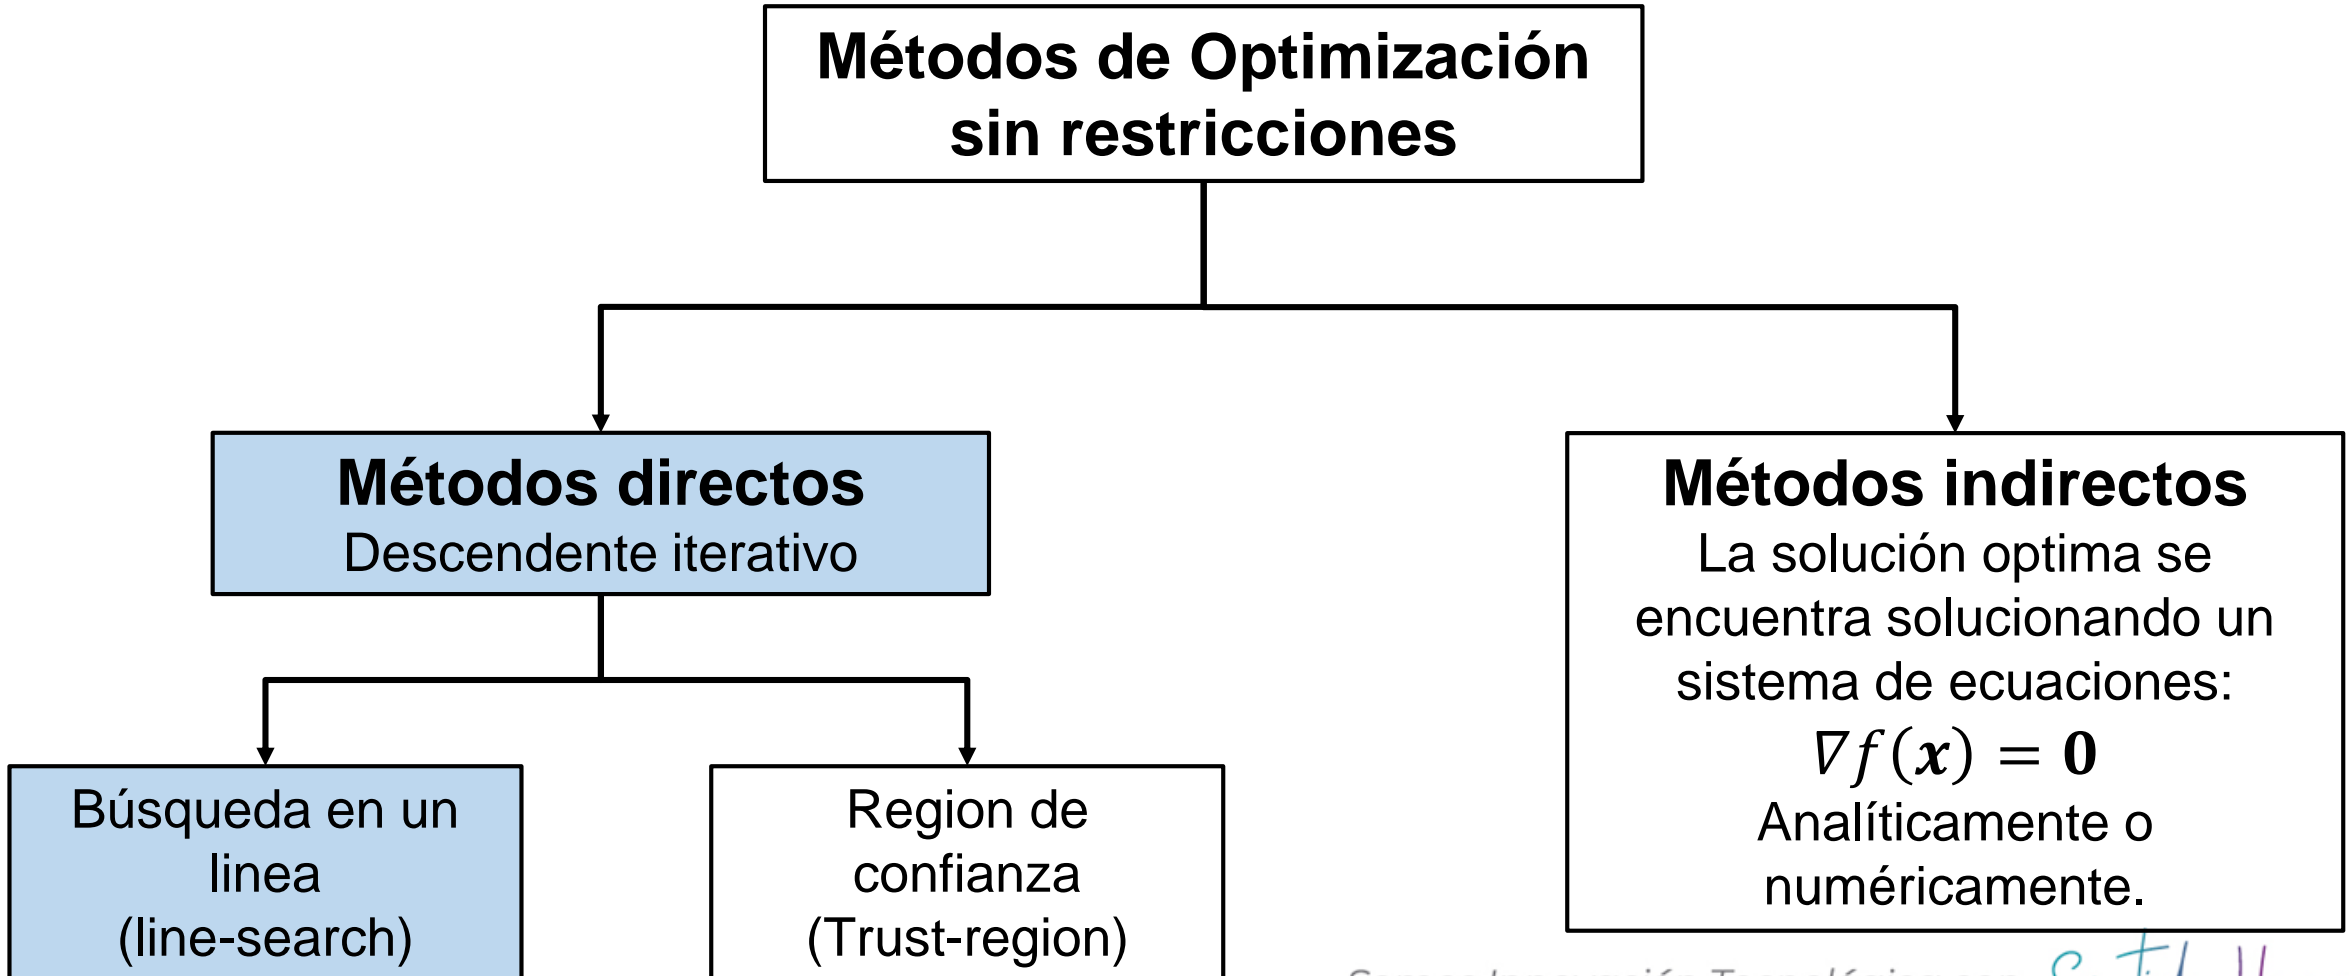




# Contenido

1. Métodos de solución para Optimización sin restricciones.
2. **Búsqueda en una línea.** (Condiciones de Armijo y Wolfe seleccionar paso)
3. Determinación de la dirección (Steepest, Conjugate, Newton's)

# Métodos de solución para Optimización sin restricciones



# Búsqueda en una línea


## Definición (dirección descendente):

Un vector  $\mathbf{p}$  es llamado dirección descendente en  $\mathbf{x}^{(k)}$ , si  $\nabla f(\mathbf{x}^{(k)})^T \mathbf{p} < 0$  se mantiene.

## Algoritmo básico (line-search):

1. Seleccionar ya dirección descendente,  $\mathbf{p}^{(k)}$ , tal que  

$$\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} < 0$$
2. Determinar el tamaño el paso  $\alpha_k$
3. Calcular  $\mathbf{x}^{(k)+1} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}$



## Problemas abiertos:

1. Determinar la dirección del descendente  $\mathbf{p}^{(k)}$ ?
2. Calcular el tamaño el paso  $\alpha_k$ .

## Calculo del paso $\alpha_k$

### Algoritmo básico (line-search):

1. Definir una función de una dimensión sobre la dirección descendente  $\mathbf{p}^{(k)}$

$$\phi(\alpha) = \nabla f(\mathbf{x}^{(k)} + \mathbf{p}^{(k)})$$


2. Solucionar el problema de minimización de una dimensión

$$\min_{\alpha > 0} \phi(\alpha)$$

### Observaciones:

1. De manera ingenua seria ideal minimizer globalmente  $\phi(\alpha)$ . Generalmente, es muy costoso encontrar esta solución. No es necesariamente una buena idea buscar en una dimensión.
2. Se podría buscar alguna solución local. Pero esto es a menudo costoso (se necesita evaluar la función y/o gradientes en un número de puntos).
3. Estrategias prácticas (también llamadas **LS no exacto**): encontrar  $\alpha$  tal que  $\nabla f(\mathbf{x}^{(k+1)})$  se vuelva lo más posible pequeño con el esfuerzo mínimo.

# Estrategias de búsqueda en una linea




# Condición de Armijo

## Teorema:

Sea  $f$  continuamente diferenciable,  $\mathbf{p}^{(k)}$  una dirección descendiente, y sea  $c_1 \in (0,1)$ . Entonces existe un  $\alpha > 0$ , tal que para  $\phi(\alpha) := f(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)})$ , la condición  $\phi(\alpha) \leq \phi(0) + \alpha c_1 \phi'(0)$  se mantiene.

## Interpretación geométrica:





# Algoritmo simple de búsqueda en una línea

## Observaciones:

1. La selección del tamaño del paso, que cumpla con la condición de Armijo garantiza el descendiente de  $f$ .

$\phi'(0) \leq \nabla f(\mathbf{x}^{(k)})^\top \mathbf{p}^{(k)} < 0$  ( $\mathbf{p}^{(k)}$  es una dirección descendente)

$$\phi(\alpha) \leq \phi(0) + \alpha c_1 \phi'(0) \rightarrow \phi(\alpha) < \phi(0)$$

2. La selección de  $c_1$  es crucial:

- Valores grande de  $c_1$  nos llevan a valores pequeños de  $\alpha$ . Entonces  $\mathbf{x}^{(k+1)} \approx \mathbf{x}^{(k)}$ .
- Un pequeño  $c_1$  resulta potencialmente en una pequeña reducción de  $f$  y entonces la convergencia es mas lenta.

Simple line-search algorithm:

**choose**  $\alpha_1 > 0; \rho, c_1 \in (0,1)$

**set**  $\alpha = \alpha_1$

**repeat**  $\alpha \leftarrow \rho\alpha$  until  $\phi(\alpha) \leq \phi(0) + \alpha c_1 \phi'(0)$

ógica con *Sentido Humano*

# Algoritmo mejorado de búsqueda en una línea

**Seleccionar**  $\alpha_0 > 0$  y  $c_1 \in (0,1)$

**If**  $\phi(\alpha) \leq \phi(0) + \alpha c_1 \phi'(0)$  **PARAR, else**

**Encontrar** una mayor solución  $\alpha \in (0, \alpha_0)$  por medio de una interpolación cuadrática de los datos disponibles:

$$\alpha_1 = \frac{\phi'(0)\alpha_0^2}{2[\phi(\alpha_0) - \phi(0) - \phi'(0)\alpha]}$$

**If**  $\phi(\alpha) \leq \phi(0) + \alpha c_1 \phi'(0)$  **PARAR, else**

**Encontrar** una mayor solución  $\alpha \in (0, \alpha_1)$  por medio de una interpolación cúbica (como?)


**Repetir** el procedimiento de la interpolación cúbica, hasta que la condición se cumpla.

# Condición de Wolfe

## Teorema:

Sea  $f$  continuamente diferenciable,  $\mathbf{p}^{(k)}$  una dirección descendiente, y sea  $c_1 \in (0,1)$ ,  $c_2 \in (c_1, 1)$ . Entonces existe un  $\alpha > 0$ , tal que  $\phi(\alpha) \leq \phi(0) + \alpha c_1 \phi'(0)$   
 $\phi(\alpha) \geq c_2 \phi'(0)$  (condición de pendiente)

## Interpretación geométrica:



Las condiciones de Wolfe promueven la convergencia a un punto estacionario.

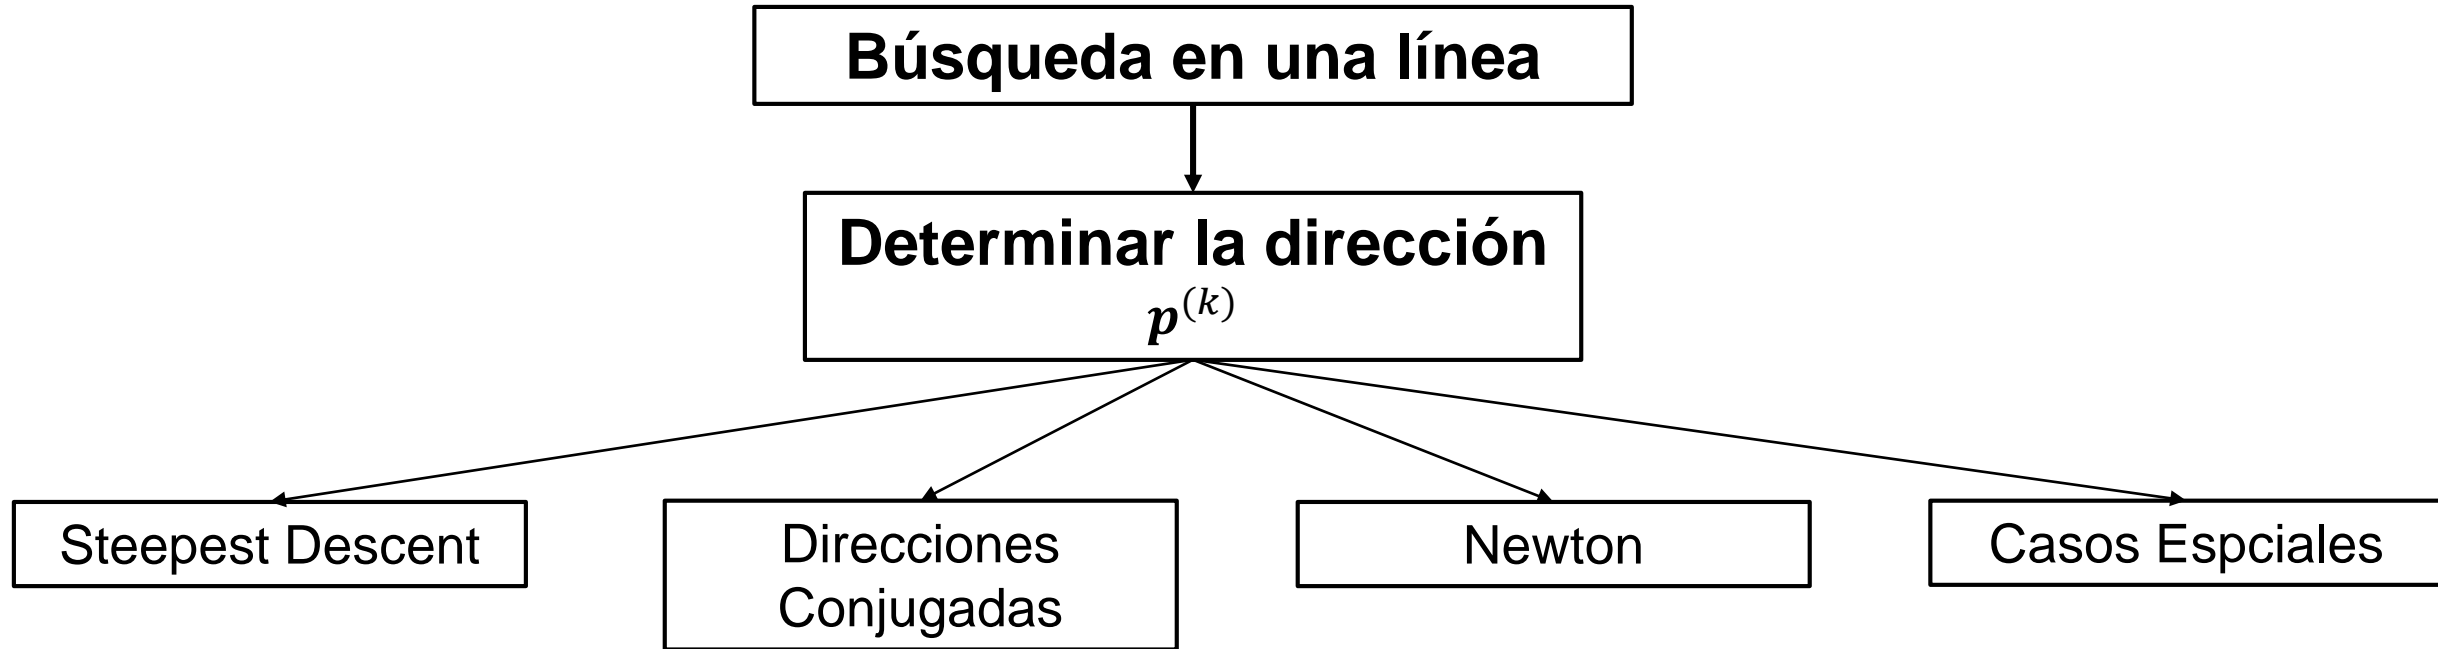


# Contenido

1. Métodos de solución para Optimización sin restricciones.
2. Búsqueda en una línea. (Condiciones de Armijo y Wolfe seleccionar paso)
3. Determinación de la dirección (Steepest, Conjugate, Newton's)

# Determinación de la dirección

Los métodos de búsqueda en una línea difieren el uno del otro con respecto a la determinación de la dirección del descendiente y el tamaño del paso.



Muchos métodos de gradiente usan matrices definidas positivas  $\mathbf{D}^{(k)}$  y calculan

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \mathbf{D}^{(k)} \nabla f(\mathbf{x}^{(k)})$$

# Steepest-Descent

Series de Taylor:  $f(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)}) = f(\mathbf{x}^{(k)}) + \alpha \nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} + O(\alpha^2)$

La razón del cambio de  $f$  en  $\mathbf{x}^{(k)}$  en la dirección  $\mathbf{p}^{(k)}$  es el coeficiente en expresión lineal

$$\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)}$$

La dirección unitaria con el mayor cambio es la solución del siguiente problema

$$\min_{\mathbf{p}^{(k)} \in \mathbb{R}^n} \nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} \quad \text{s. t. } \|\mathbf{p}^{(k)}\| = 1$$

Note que  $\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} = \|\nabla f(\mathbf{x}^{(k)})\| \|\mathbf{p}^{(k)}\| \cos(\theta)$

La solución del problema se alcanza para  $\cos(\theta) = -1 \Rightarrow \theta = \pi$


$$\Rightarrow \mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)}) / \|\nabla f(\mathbf{x}^{(k)})\|$$

La selección de  $\mathbf{D}^{(k)}$  es la matriz identidad  $\mathbf{I}$ .

# Steepest-Descent

descent direction:  $\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} < 0$

$$\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} = \|\nabla f(\mathbf{x}^{(k)})\| \|\mathbf{p}^{(k)}\| \cos(\theta)$$





# Steepest-Descent

Algorithm:

choose  $\mathbf{x}^{(0)}$

for  $k=0, 1, \dots$



if  $\|\nabla f(\mathbf{x}^{(k)})\| \leq \varepsilon$  stop, else

set  $\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$

determine the step length  $\alpha_k$  (e.g.  
using the Armijo rule)

set  $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}$

end for



# Referencias

- Basado en el curso “Applied Numerical Optimization” por el profesor Alexander Mitsos.
- Nocedal J. Wright S. J. Numerical Optimization, 2nd Edition, Springer, 2006.



Institución  
**Universitaria**  
Reacreditada en Alta Calidad

# *¡Gracias!*

Somos Innovación Tecnológica con *Sentido Humano*



Alcaldía de Medellín